TRABALHO 1 — REDES NEURONAIS ARTIFICIAIS

Análise e Engenharia de Atributos para a Previsão de CO(GT)

DISCENTES

Guilherme Basílio (2100123)

Carlos Santos (2128623)



INTRODUÇÃO AO ESTUDO

Contexto e Objetivos

Problema Central

Monitorização contínua de poluição urbana com recurso a matrizes de sensores químicos de óxido metálico de baixo custo.

Desafios Físicos

Deriva de sensores, sensibilidade cruzada entre múltiplos gases e perdas de calibração em campo.

Dataset UCI Air Quality

9358 registos horários recolhidos ao longo de 1 ano numa via urbana italiana com tráfego intenso.

Meta do Trabalho

Pré-processar, selecionar e derivar atributos para prever a concentração de CO(GT) numa futura Rede Neuronal Artificial.

EXPLORAÇÃO INICIAL

Diagnóstico de Falhas e Alvo

Marcador de Valores Omissos

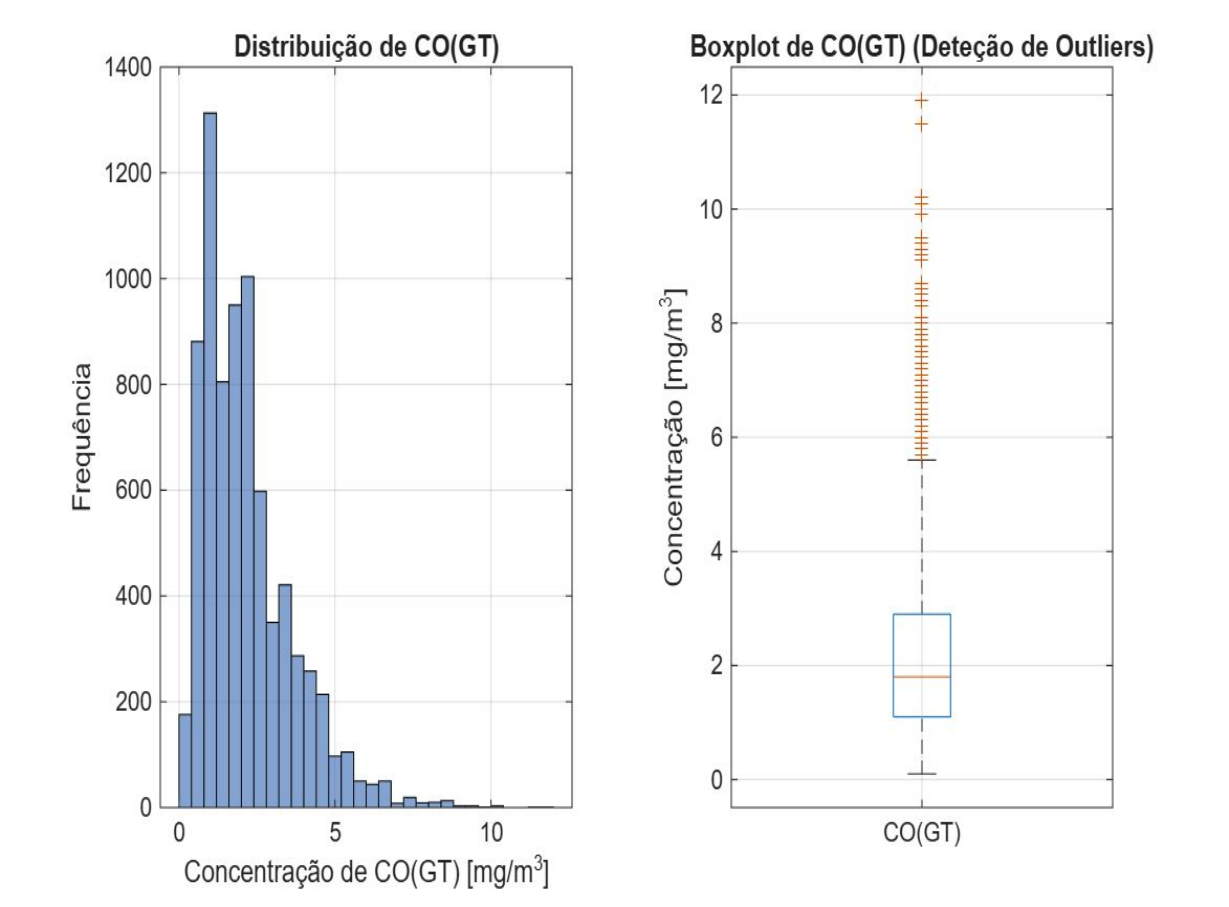
Identificação de valores -200 mapeados para NaN (16 701 falhas totais no conjunto de dados).

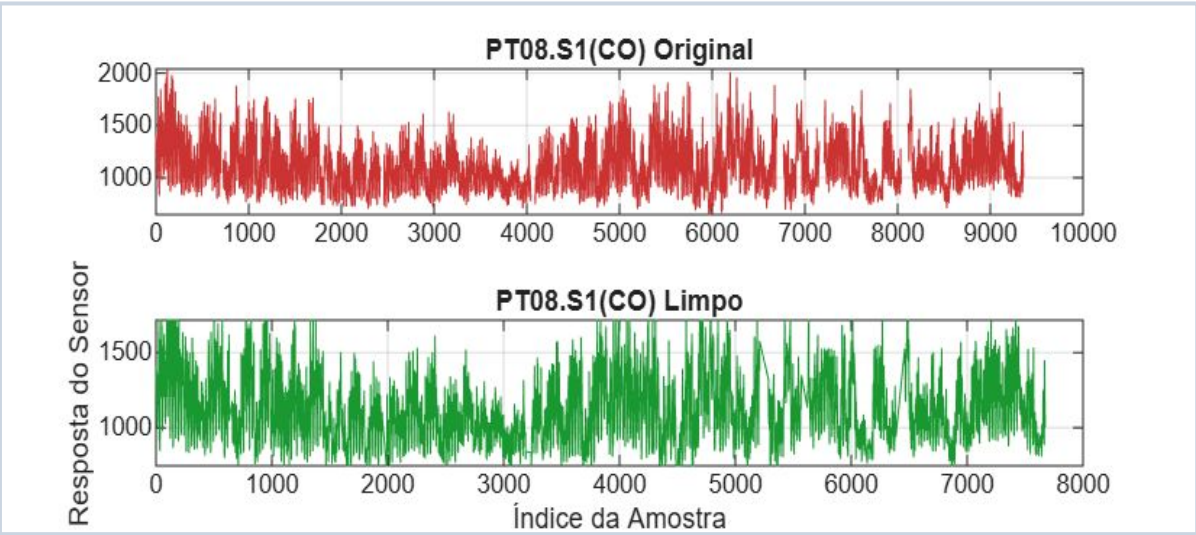
Caso Crítico: NMHC(GT)

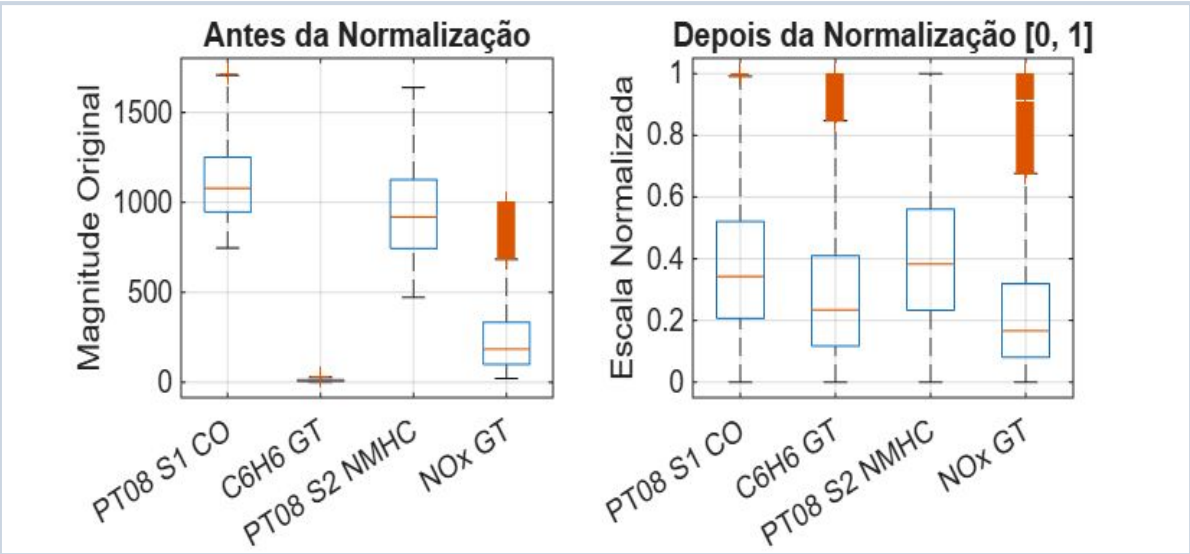
90.23% de omissões inviabilizam qualquer imputação estatística → descarte definitivo.

Comportamento do Alvo CO(GT)

17.99% de omissões (1683 amostras); distribuição com forte assimetria positiva (1.37) e picos de 11.9 mg/m³.







PRÉ-PROCESSAMENTO

Limpeza e Pré-processamento

Integridade do Alvo

Remoção estrita das 1683 linhas sem CO(GT) (mantêm-se 7674 instâncias válidas para treino supervisionado).

Imputação Temporal

Interpolação linear contínua nas *features* para preservar a dinâmica atmosférica entre horas consecutivas.

Atenuação de Outliers

Clipping entre percentis 1% e 99% elimina saturações elétricas nos transdutores.

Normalização Min-Max [0, 1]

Harmonização de escalas físicas para evitar o domínio de gradientes na rede neuronal.

ANÁLISE EXPLORATÓRIA (EDA)

Relações Bivariadas com o Alvo

Saturação Química

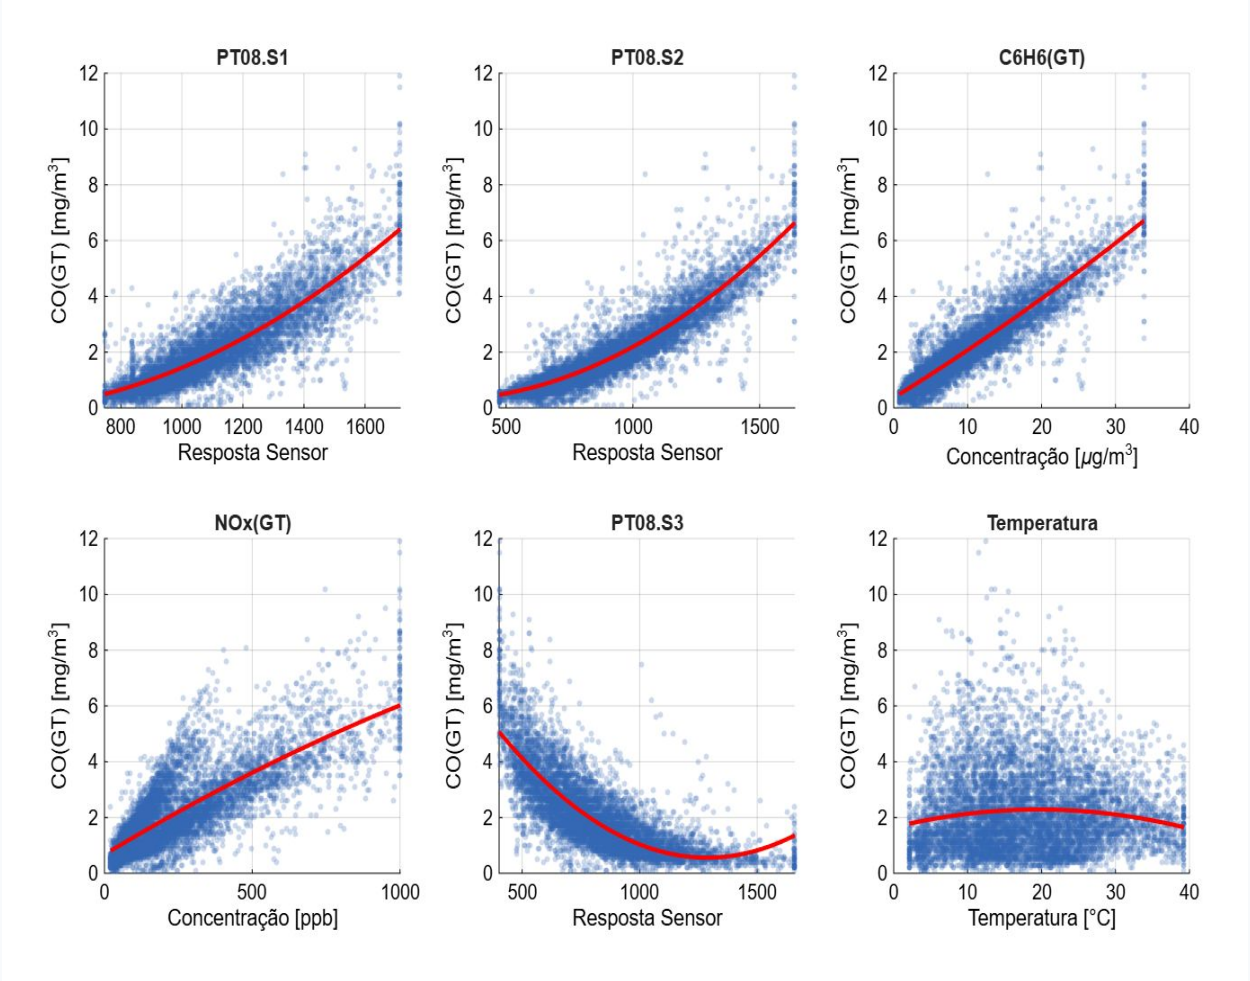
Sensores PT08.S1 e PT08.S2 apresentam curvatura convexa em concentrações elevadas (saturação dos sítios de adsorção).

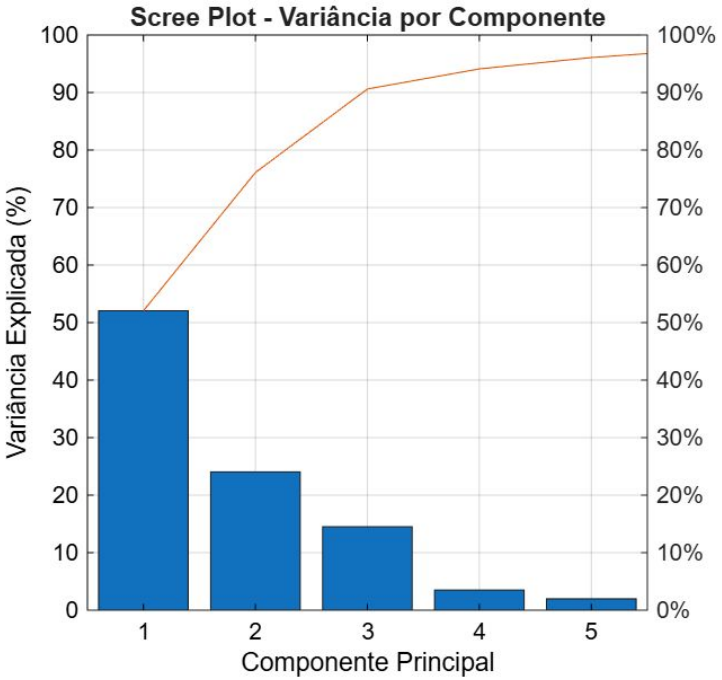
Correlação Direta

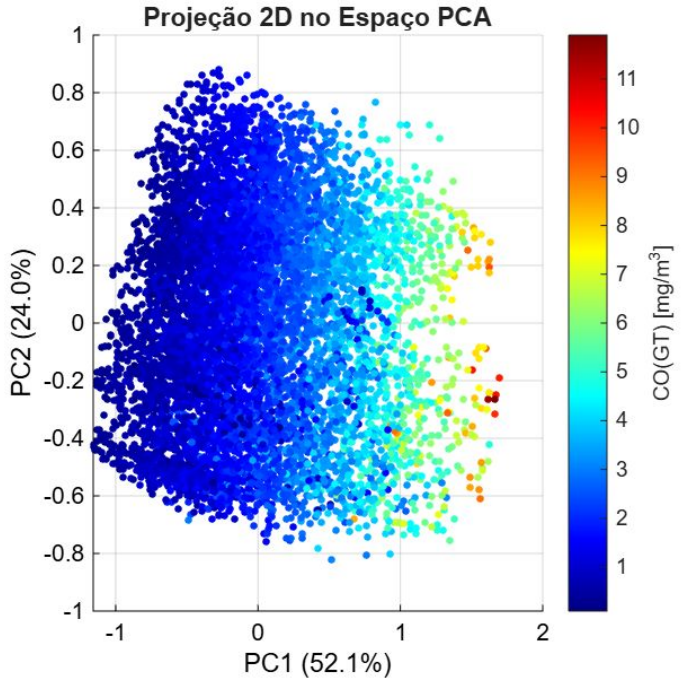
C6H6(GT) apresenta comportamento linear puro (r = 0.93) devido à co-emissão na queima veicular.

Comportamento Inverso & Clima

PT08.S3(NOx) exibe curva hiperbólica decrescente perante gases oxidantes; Temperatura (T) apresenta nuvem difusa sem relação direta.







ANÁLISE EXPLORATÓRIA (EDA)

Análise de Componentes Principais (PCA)

Compressibilidade Espectral (Scree Plot)

PC1 retém 52.1% da variância e PC2 retém 24.0% (≈ 76.1% acumulada em apenas 2 eixos ortogonais).

Separabilidade no Espaço Latente

A projeção PC1–PC2 revela um gradiente contínuo e bem demarcado da concentração de CO(GT).

Adequação Conexionista

Prova que uma rede neuronal conseguirá separar regimes de baixa e alta poluição sem necessitar de elevadas dimensões.

ANÁLISE EXPLORATÓRIA (EDA)

Multicolinearidade e Redundância

Matriz Cruzada

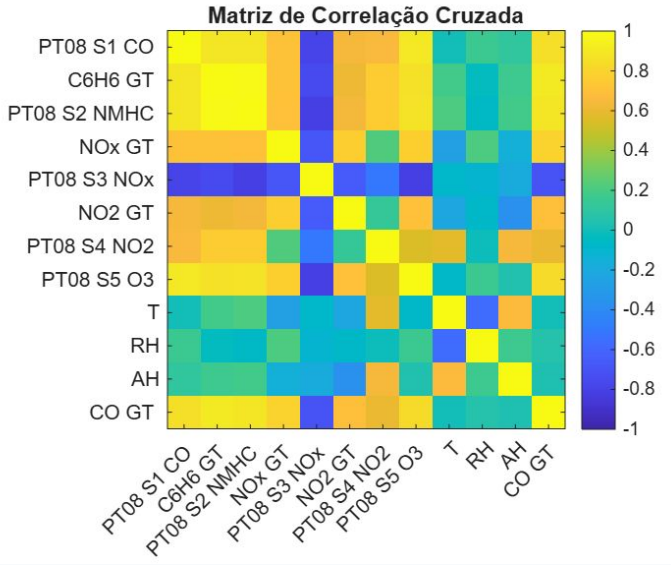
Blocos colineares densos (r > 0.90) entre PT08.S1, PT08.S2, C6H6 e PT08.S5.

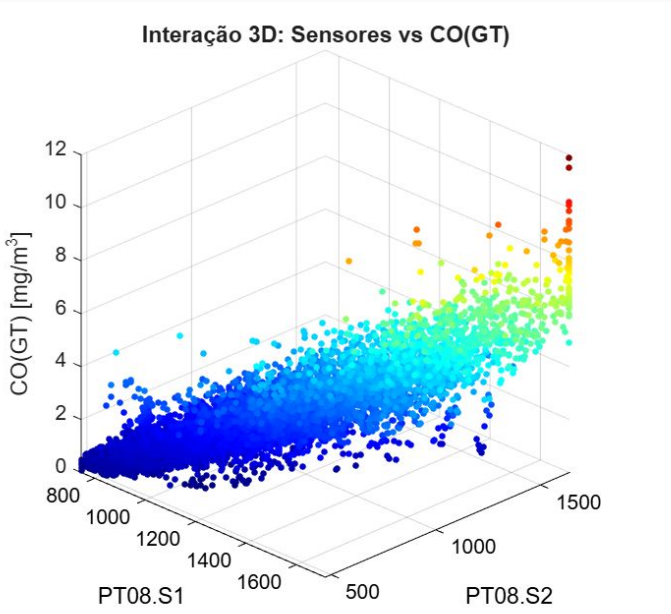
Sobreposição Física

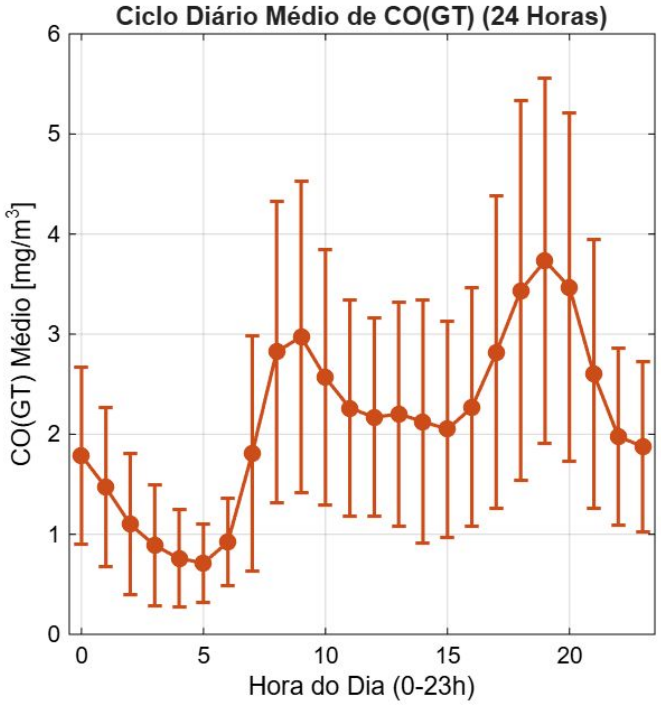
Reta quase univariada (r = 0.89) entre PT08.S1 e PT08.S2.

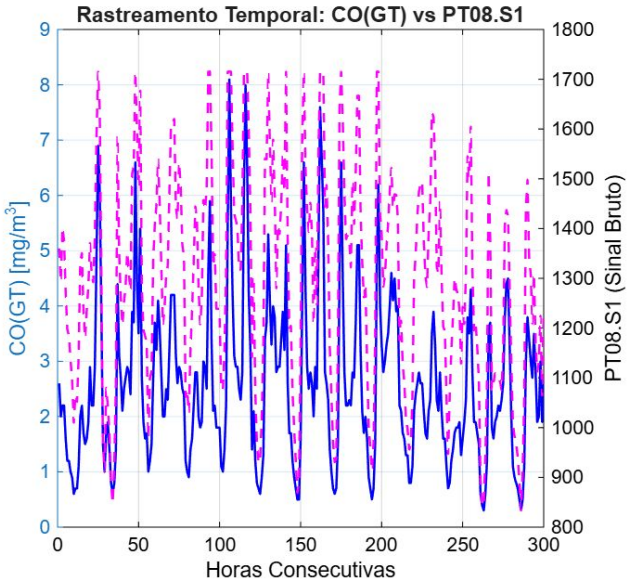
Risco Conexionista

Superfícies de erro planas dificultam treino por retropropagação.









ANÁLISE EXPLORATÓRIA (EDA)

Padrões Temporais e Ciclo Diário

Perfil Bimodal de 24 Horas

Picos diários coincidentes com trânsito urbano (09h e 19h, ~4.0 mg/m³).

Mínimos Noturnos

Queda substancial da concentração entre as 03h e as 05h da madrugada.

Sincronia Temporal

Sensor PT08.S1 acompanha flutuações de CO(GT) com resposta dinâmica imediata.

MÉTODOS DE SELEÇÃO

Filtros e Subconjunto Eleito

Critério 1: Filtro Fraco (|r| < 0.15)

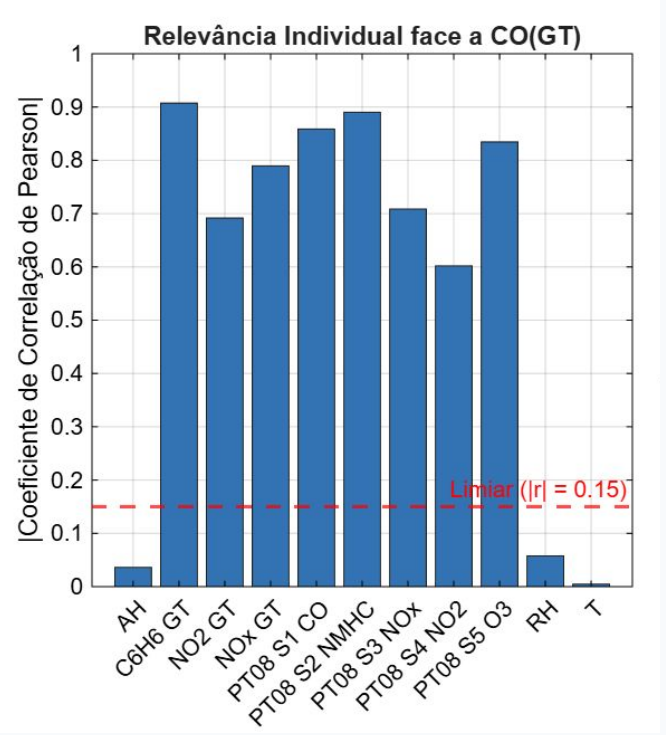
Exclusão das variáveis meteorológicas (T, RH, AH) por correlação nula com o alvo (r ≤ 0.058).

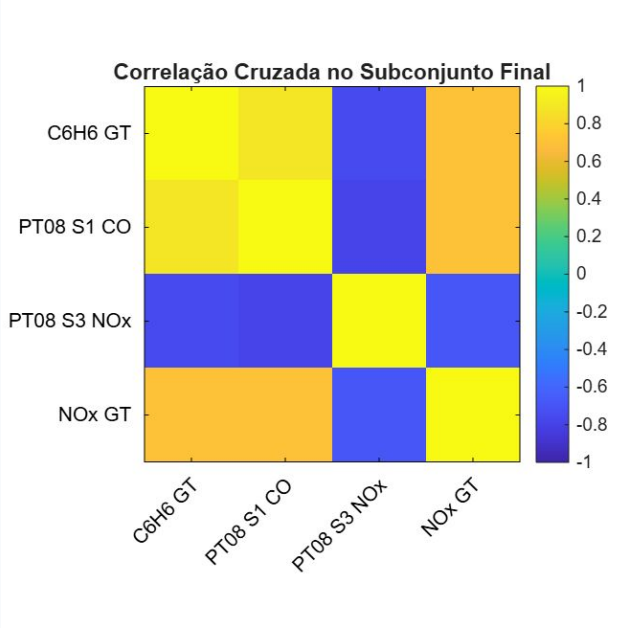
Critério 2: Filtro de Redundância ($|r_{ij}| > 0.85$)

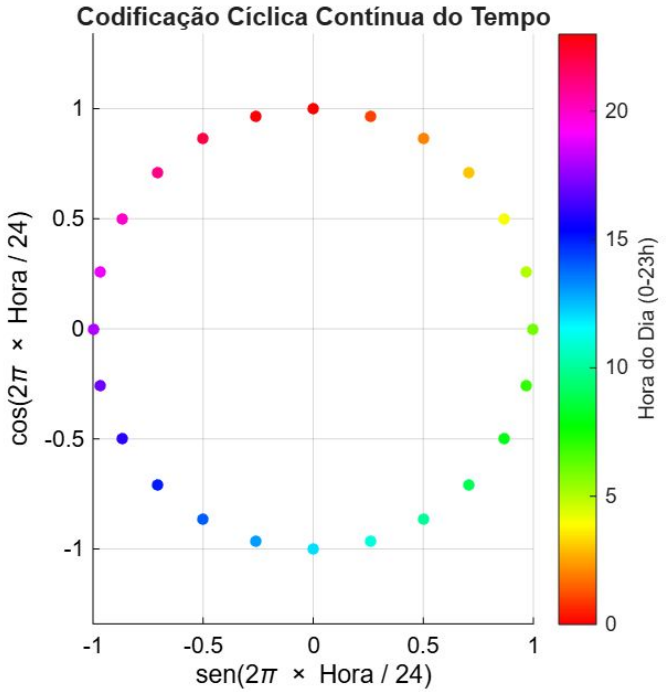
Remoção dos sensores redundantes PT08.S2, PT08.S5, PT08.S4 e da medição NO2(GT).

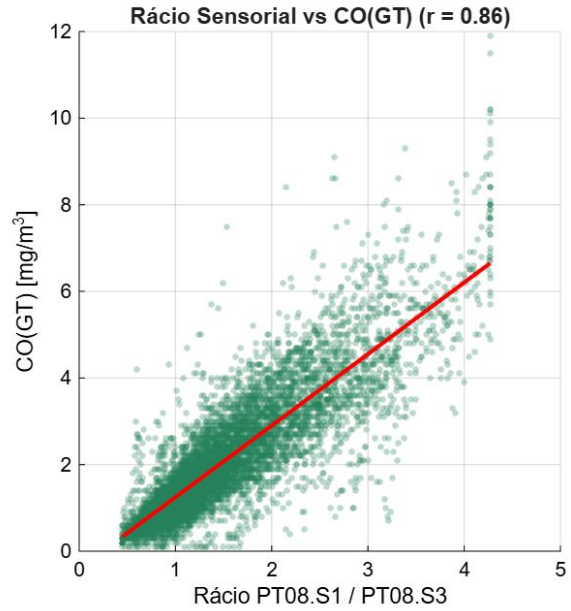
Subconjunto Eleito (4 Variáveis)

C6H6(GT) (r=0.91), PT08.S1(CO), PT08.S3(NOx) (r=-0.71) e NOx(GT).









ENGENHARIA DE ATRIBUTOS

Engenharia de Novos Atributos

Codificação Cíclica (Hour_Sin, Hour_Cos)

Mapeamento trigonométrico contínuo de 24h que resolve a descontinuidade artificial entre as 23h e as 00h.

Rácio Químico Sensorial (Ratio_S1_S3)

Fórmula PT08.S1 / (PT08.S3 + ε), combinando o sensor de redução (S1) com o de oxidação (S3).

Linearização de Resposta

Alcança forte correlação linear (r = 0.8594) e lineariza a curva de saturação do gás.

COMPARAÇÃO FINAL

Síntese dos Resultados e Impacto nos Dados

Dimensão de Análise	Dataset Bruto	Dataset Final
Instâncias Válidas	9357 (com falhas)	**7674 (100% íntegras sem imputação do alvo)**
Omissões / NaNs	16 701 valores	**0**
Features de Entrada	12 variáveis	**7 atributos desacoplados**
Relação com o Ciclo Urbano	Discreta / Quebrada	**Contínua (Hour_Sin, Hour_Cos)**
Multicolinearidade Extrema	Presente (r > 0.95)	**Eliminada**
Linearização de Resposta	Saturação visível	**Maximizada (Ratio_S1_S3, r = 0.86)**

CONCLUSÕES

Conclusões

Limpeza e Filtros

Limpeza temporal e normalização corrigiram anomalias sem descaracterizar a dispersão física real.

Engenharia Preditiva

Filtragem e novos atributos acrescentaram poder preditivo e estabilidade aos sensores semicondutores.