Análise e Engenharia de Atributos para a Previsão de CO(GT) no Dataset UCI Air Quality

Guilherme Basílio - 2100123
Faculdade de Ciências Exatas e da Engenharia
Universidade da Madeira
Funchal, Portugal
2100123@student.uma.pt

Carlos Santos - 2128623
Faculdade de Ciências Exatas e da Engenharia
Universidade da Madeira
Funchal, Portugal
2128623@student.uma.pt

***Abstract*—Resumo sucinto dos objetivos, metodologia de pré-processamento, seleção e engenharia de atributos e principais conclusões obtidas sobre a previsão da concentração de CO(GT).**

***Index Terms*—Qualidade do Ar, Engenharia de Atributos, Seleção de Atributos, Pré-processamento de Dados, Redes Neuronais, MATLAB.**

I. Introdução

A monitorização contínua e fidedigna da qualidade do ar em ambientes urbanos constitui um desafio crucial de saúde pública e sustentabilidade ambiental. Contudo, as estações convencionais de medição analítica de referência apresentam elevados custos de instalação e manutenção, limitando a sua proliferação espacial. Como alternativa, a utilização de matrizes de sensores químicos multiespécies baseados em semicondutores de óxido metálico tem vindo a ganhar destaque, viabilizando redes de monitorização densas a custos reduzidos.

Neste contexto, o presente trabalho incide sobre o conjunto de dados *Air Quality*, disponibilizado pelo repositório *UC Irvine Machine Learning*. Este repositório agrega 9358 registos horários recolhidos ao longo de um período contínuo de um ano (março de 2004 a fevereiro de 2005) por um dispositivo multissensor situado ao nível da estrada numa área urbana poluída de Itália. Os dados contêm tanto as respostas dos sensores em campo como as concentrações reais medidas em paralelo por analisadores certificados co-localizados para poluentes como o monóxido de carbono (CO), hidrocarbonetos não-metânicos (NMHC), benzeno (C_6H_6) e óxidos de azoto (NO_x, NO_2), para além de grandezas ambientais de temperatura e humidade. No entanto, a operação destes dispositivos em condições reais expõe os dados a fenómenos complexos, tais como desvios operacionais dos sensores, sensibilidade cruzada a múltiplos gases e períodos prolongados de falhas ou saturação do sinal.

O objetivo central deste trabalho consiste no desenvolvimento de um pipeline rigoroso de exploração, limpeza, transformação, seleção e engenharia de atributos com recurso ao ambiente MATLAB. No âmbito deste estudo, a concentração de monóxido de carbono horário (CO(GT)) é fixada como a variável-alvo, devendo as restantes variáveis ser transformadas em atributos preditores de entrada. Procura-se, assim, preparar e otimizar a representação do conjunto de dados para posterior integração em modelos de regressão baseados em Redes Neuronais Artificiais, assegurando que o ruído, os valores anómalos e as multicolinearidades sejam mitigados de forma justificada e documentada.

II. Metodologia

A. Importação e Exploração dos Dados

O conjunto de dados *UC Irvine Air Quality* foi importado via MATLAB através do dataset *.xlsx* fornecido. Identificou-se que o valor -200, adotado pelo sistema de aquisição para assinalar falhas operacionais dos sensores, correspondia a medições inexistentes, tendo sido imediatamente alterado para `NaN`. O conjunto é composto por 9357 observações e 15 variáveis originais, totalizando 16 701 valores ausentes.

A Tabela I resume as propriedades estatísticas fundamentais de todas as grandezas numéricas, bem como a respetiva correlação linear de Pearson face à variável-alvo, CO(GT).

TABLE I
Propriedades Estatísticas Descritivas e Proporção de Valores em Falta face ao Alvo CO(GT)

Variável	Válidos	Faltas (%)	Mín.	Máx.	Média	Desv. Padrão	Assimetria	Corr. CO
CO(GT)	7674	17.99%	0.10	11.90	2.15	1.45	1.37	1.000
PT08.S1 (CO)	8991	3.91%	647.25	2039.80	1099.70	217.08	0.76	0.879
NMHC(GT)	914	90.23%	7.00	1189.00	218.81	204.46	1.56	0.890
C6H6(GT)	8991	3.91%	0.15	63.74	10.08	7.45	1.36	0.931
PT08.S2 (NMHC)	8991	3.91%	383.25	2214.00	939.03	266.83	0.56	0.916
NOx(GT)	7718	17.52%	2.00	1479.00	246.88	212.97	1.72	0.795
PT08.S3 (NOx)	8991	3.91%	322.00	2682.80	835.37	256.82	1.10	-0.703
NO2(GT)	7715	17.55%	2.00	339.70	113.08	48.36	0.62	0.684
PT08.S4 (NO2)	8991	3.91%	551.00	2775.00	1456.10	346.20	0.21	0.631
PT08.S5 (O3)	8991	3.91%	221.00	2522.80	1022.80	398.48	0.63	0.854
T	8991	3.91%	-1.90	44.60	18.32	8.83	0.31	0.022
RH	8991	3.91%	9.18	88.73	49.23	17.32	-0.04	0.049
AH	8991	3.91%	0.18	2.23	1.03	0.40	0.25	0.049

A análise preliminar evidencia particularidades determinantes para as etapas seguintes:

1) Inviabilidade de NMHC(GT): Esta variável apresenta 90.23% de omissões devido a falhas prolongadas no equipamento de referência, inviabilizando técnicas estatísticas por imputação e justificando a sua remoção do conjunto.

2) Comportamento do Alvo: A concentração de CO(GT) possui acentuada assimetria positiva (1.37), com concentração de observações em valores inferiores a $3.0\,\mathrm{mg/m^3}$ e cauda longa à direita com múltiplos episódios de pico de poluição (Fig. 1).

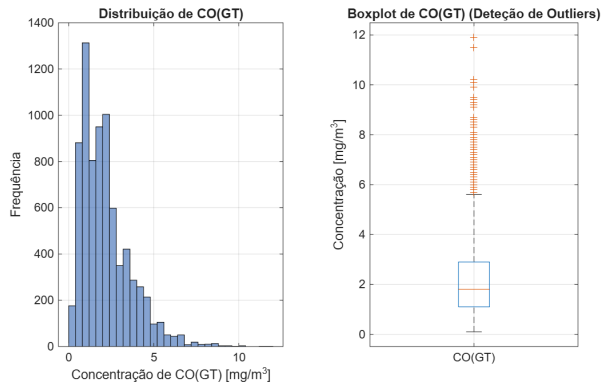


Fig. 1. Distribuição da variável alvo e diagrama de extremos e quartis da variável-alvo CO(GT).

3) Grau de Associação: Constatam-se correlações muito fortes entre CO(GT) e os sensores PT08.S1, PT08.S2, bem como com o C6H6(GT) ($r > 0.85$), antecipando forte capacidade preditiva destas variáveis. Em contrapartida, as grandezas meteorológicas (T, RH, AH) exibem coeficientes praticamente nulos ($r < 0.05$) (Fig. 2).

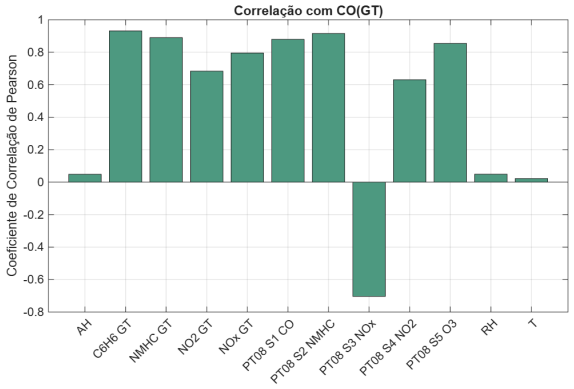


Fig. 2. Correlação linear de Pearson de cada atributo com o alvo CO(GT).

B. Limpeza e Pré-processamento dos Dados

A presença de leituras em falta, descontinuidades temporais e magnitudes diferentes compromete a estabilidade numérica e a capacidade de convergência do algoritmo de retropropagação numa Rede Neuronal Artificial. Deste modo, delineou-se um procedimento de transformação dos dados estruturado em quatro etapas:

1) Identificação e Tratamento de Omissões e Anomalias: Os valores em falta foram identificados através do marcador -200, característico do sistema de aquisição do sensor. Conforme diagnosticado na fase preliminar, o atributo NMHC(GT) apresentava 90.23% de falhas por indisponibilidade prolongada do equipamento de referência, inviabilizando qualquer método estatístico de imputação; como tal, esta coluna foi descartada.

Relativamente à variável-alvo CO(GT), registaram-se 1683 instâncias nulas. Optou-se pela eliminação definitiva das linhas onde o alvo estava ausente, reduzindo o conjunto amostral para 7674 observações válidas. Esta decisão justifica-se pelo rigor da aprendizagem supervisionada: imputar artificialmente a grandeza de referência distorceria o padrão real de erro e introduziria viés no treino do preditor.

2) Imputação Temporal nas Entradas: Nos atributos preditores restantes (com apenas 3.91% de omissões nos sensores e grandezas meteorológicas, e cerca de 17.5% nos analisadores de NO_x e NO_2), aplicou-se interpolação linear temporal. Por se tratar de um fenómeno físico de dispersão atmosférica amostrado horariamente, a interpolação contínua preserva a dependência temporal e as transições suaves entre horas consecutivas com maior fidelidade do que estimadores estáticos de tendência central. As falhas nas extremidades temporais foram colmatadas com base no vizinho mais próximo.

3) Atenuação de Outliers por Corte (*Clipping*): Para mitigar valores anormais, aplicou-se a técnica de *clipping* entre os percentis 1% e 99%:

A Tabela II detalha o efeito desta operação na variável PT08.S1(CO), onde os extremos anómalos foram contidos no intervalo $[746.36, 1715.34]$, estabilizando a dispersão sem alterar a média global. O impacto na continuidade do sinal temporal é ilustrado na Fig. 3.

TABLE II
EFEITO DO PRÉ-PROCESSAMENTO E *Clipping* NO SENSOR PT08.S1(CO)

Estado	Média	Desv. Padrão	Mínimo	Máximo
Antes da Limpeza	1099.71	217.08	647.25	2039.75
Após Limpeza	1112.58	216.30	746.36	1715.34

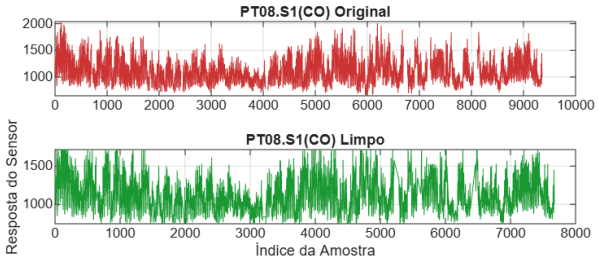


Fig. 3. Comparação temporal da resposta de PT08.S1(CO)

4) Normalização Min-Max: Antes da normalização, verificou-se uma grande disparidade nas escalas físicas: grandezas como PT08.S1 operam em magnitudes superiores a 1000, enquanto o C6H6(GT) apresenta valores na ordem das dezenas. Se fornecidas diretamente a uma rede neuronal, as grandezas de maior magnitude dominariam a atualização inicial dos pesos pelas derivadas parciais. Para harmonizar as variáveis, aplicou-se normalização linear Min-Max ao intervalo $[0, 1]$:

Na Fig. 4 observa-se a homogeneização de escalas obtida em quatro atributos de entrada, garantindo a preservação da

forma distributiva e da variabilidade relativa sob o mesmo domínio.

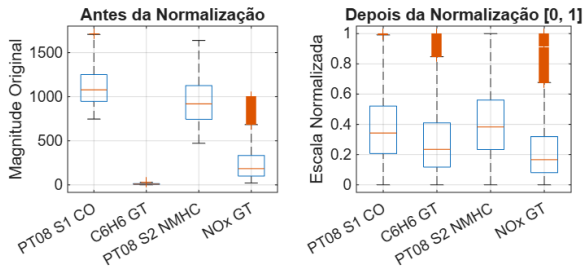


Fig. 4. Boxplot de quatro atributos de entrada antes da normalização (esquerda) e após normalização (direita).

C. Análise Exploratória de Dados (EDA)

Após os procedimentos de limpeza e normalização dos dados, realizou-se uma exploração multidimensional sistemática para caraterizar o comportamento físico dos sinais, avaliar a assimetria distributiva, detetar não-linearidades e diagnosticar redundâncias colineares face à variável-alvo CO(GT).

1) Relações Funcionais e Não-Linearidade com o Alvo: A Fig. 5 sintetiza o mapeamento bivariado em unidades físicas reais entre os principais atributos preditores e a concentração de CO(GT).

- Os sensores PT08.S1(CO) e PT08.S2(NMHC) apresentam um comportamento crescente com curvatura convexa ajustada pela curva polinomial, denotando princípios de saturação nos sítios de adsorção química dos semicondutores à medida que a concentração de gás aumenta.
- A medição analítica de C6H6(GT) exibe uma dependência linear quase pura com o alvo ($r = 0.93$), confirmando que ambos partilham a mesma fonte geradora (emissões de escape de motores a combustão).
- O sensor PT08.S3(NOx) evidencia uma relação hiperbólica decrescente acentuada, onde valores reduzidos do sinal correspondem a episódios de elevadíssima poluição por CO, refletindo o mecanismo elétrico inverso típico de óxidos de tungsténio perante gases oxidantes.
- A temperatura (T) apresenta uma nuvem difusa sem correlação discernível com a variável-alvo, demonstrando que o clima local não dita, de forma isolada, a concentração instantânea de monóxido de carbono.

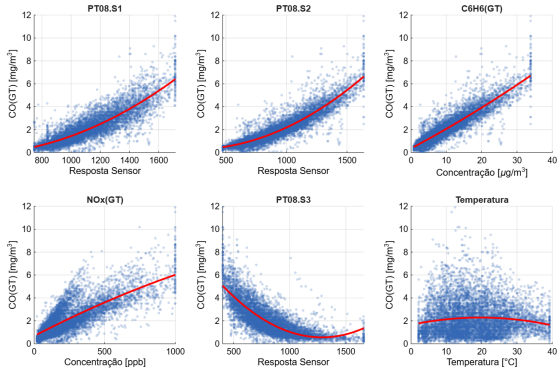


Fig. 5. Diagramas de dispersão em unidades físicas reais com ajuste polinomial quadrático face ao alvo CO(GT).

2) Análise por Componentes Principais (PCA): Para averiguar a viabilidade de compressão do espaço vetorial sem perda de informação crítica, aplicou-se PCA sobre os dados normalizados. Conforme exposto no *Scree Plot* (Fig. 6, esquerda), os dois primeiros eixos concentram 76.1% da variância total (52.1% em PC_1 e 24.0% em PC_2). Na projeção 2D (Fig. 6, direita), constata-se um gradiente cromático contínuo de CO(GT) ao longo do eixo horizontal, provando que a primeira componente sintetiza eficazmente a severidade da poluição fotoquímica e proporciona excelente separabilidade para uma rede neuronal.

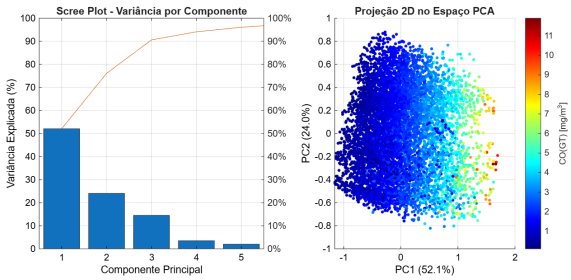


Fig. 6. Análise PCA: variância acumulada por componente (esquerda) e mapeamento ortogonal PC_1–PC_2 colorido pelo nível de CO(GT) (direita).

3) Multicolinearidade e Interação Tridimensional: A matriz de correlação cruzada (Fig. 7, esquerda) revela agrupamentos com coeficientes lineares superiores a 0.90, especificamente no bloco formado por PT08.S1, PT08.S2, C6H6(GT) e PT08.S5. Esta multicolinearidade severa antecipa forte redundância funcional, desaconselhando a inclusão simultânea de todas estas variáveis no modelo preditivo. A representação tridimensional conjunta entre PT08.S1, PT08.S2 e CO(GT) (Fig. 7, direita) forma uma trajetória colinear delgada, corroborando a hipótese de sobreposição quase determinística de sinal entre sensores de óxido metálico.

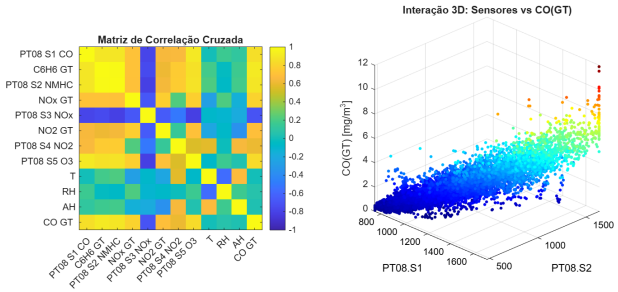


Fig. 7. Matriz de correlação (esquerda) e dispersão tridimensional evidenciando a dependência mútua entre PT08.S1, PT08.S2 e o alvo CO(GT) (direita).

4) Assimetria e Morfologia Distributiva: Os histogramas com ajuste de densidade paramétrica normal (Fig. 8) mostram que as medições analíticas pontuais de poluentes como NOx(GT) e C6H6(GT) possuem assimetria positiva, com a maioria das observações com valores baixos e uma cauda longa devido a eventos de congestionamento severo. Por outro lado, as respostas dos sensores de óxido metálico (PT08.S1, PT08.S2 e PT08.S3) e a humidade relativa apresentam distribuições mais simétricas, adequadas ao processamento por camadas densas.

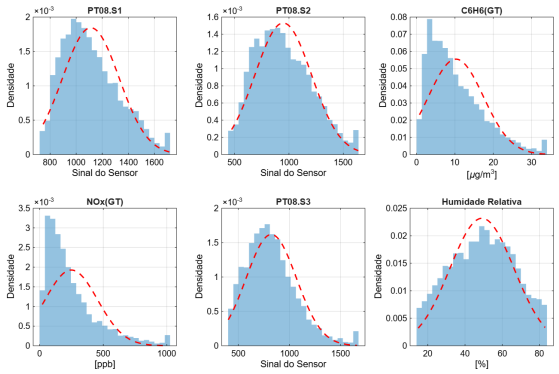


Fig. 8. Distribuição em escala física e sobreposição de densidade normal para seis grandezas, evidenciando assimetrias e dispersões operacionais.

5) Dinâmica Temporal : O ciclo horário médio de 24 horas (Fig. 9, esquerda) exibe um perfil bimodal nítido, registando dois picos de emissão coincidentes com os períodos de tráfego rodoviário intenso (09h e 19h, atingindo médias próximas de $4.0\,\mathrm{mg/m^3}$). O intervalo de dispersão diminui drasticamente durante a madrugada (03h–05h). O rastreamento temporal contínuo (Fig. 9, direita) comprova uma correlação entre o sensor PT08.S1 e a medição de CO(GT), confirmando uma resposta dinâmica rápida sem desfasamentos temporais consideráveis.

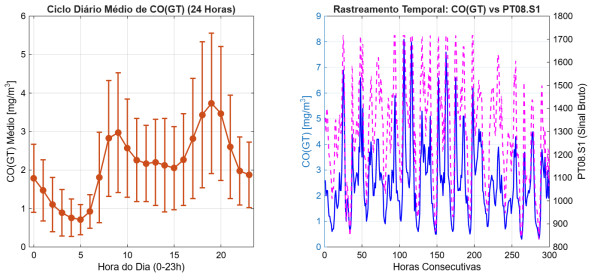


Fig. 9. Ciclo de 24 horas com desvio-padrão horário de CO(GT) (esquerda) e rastreamento temporal das primeiras 300 horas face a PT08.S1 (direita).

6) Redundância Direta e Pesos no Primeiro Componente: A dispersão entre os sensores de resposta direta PT08.S1 e PT08.S2 (Fig. 10, esquerda) confirma uma reta de correlação estreita em todo o intervalo operacional, caracterizando redundância direta entre estes sensores. No gráfico de pesos do PC1 (Fig. 10, direita), constata-se que PT08.S1, PT08.S2, C6H6(GT) e PT08.S5 partilham magnitudes similares em torno de 0.40, enquanto PT08.S3 contribui de forma inversa com -0.32, comprovando que o eixo PC_1 funciona como um índice agregador da carga poluente primária.

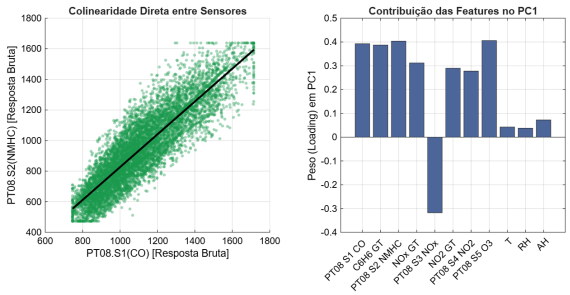


Fig. 10. Dispersão entre PT08.S1 e PT08.S2 (esquerda) e vetor de pesos dos atributos na composição de PC1 (direita).

D. Métodos de Seleção de Atributos

A presença de variáveis preditoras informativas ou altamente colineares prejudica o desempenho preditivo de Redes Neuronais Artificiais, induzindo *overfitting*, instabilidade numérica no cálculo dos gradientes e aumento desnecessário do custo computacional de treino. Para mitigar estes efeitos, implementou-se uma metodologia sequencial de seleção por filtragem fundamentada em métricas de associação bivariada e análise de multicolinearidade.

1) Relação Individual com a Variável-Alvo: Avaliou-se a capacidade explicativa individual de cada atributo face a CO(GT) através dos coeficientes de correlação linear de Pearson (r) e de postos de Spearman (ρ), sendo este último capaz de captar dependências monotónicas não-lineares. A Tabela III apresenta a ordenação decrescente de relevância obtida no conjunto de dados pré-processado.

TABLE III
ORDENAÇÃO DA RELEVÂNCIA DOS ATRIBUTOS DE ENTRADA FACE A CO(GT)

Atributo	**Pearson** (r)	**Spearman** (ρ)	$\lvert r \rvert$
C6H6(GT)	0.9074	0.9112	0.9074
PT08.S2 (NMHC)	0.8902	0.9107	0.8902
PT08.S1 (CO)	0.8587	0.8655	0.8587
PT08.S5 (O3)	0.8345	0.8429	0.8345
NOx(GT)	0.7896	0.7799	0.7896
PT08.S3 (NOx)	-0.7086	-0.8009	0.7086
NO2(GT)	0.6917	0.7431	0.6917
PT08.S4 (NO2)	0.6020	0.5749	0.6020
RH	0.0577	0.0053	0.0577
AH	0.0362	0.0399	0.0362
T	0.0047	0.0498	0.0047

2) Critérios de Remoção de Atributos: A estratégia de redução dimensional assentou em dois critérios objetivos:

- **Filtro de Relevância Fraca** ($\lvert r \rvert < 0.15$)**:** As grandezas meteorológicas isoladas (RH, AH e T) demonstraram uma correlação praticamente nula, não oferecendo qualquer impacto direto relevante para prever flutuações horárias de monóxido de carbono (Fig. 11, esquerda). Foram, por isso, excluídas da modelação.
- **Filtro de Redundância e Colinearidade** ($\lvert r_{ij} \rvert > 0.85$)**:** A análise da matriz de correlação cruzada entre os atributos candidatos revelou redundâncias severas. Destaca-se o par C6H6(GT) e PT08.S2(NMHC), com um coeficiente extremo de $r = 0.98$, evidenciando duplicação quase total de informação. O sensor PT08.S5(O3) exibiu forte colinearidade cruzada ($r = 0.9023$ com PT08.S1 e $r = 0.8728$ com PT08.S2) (Fig. 7, esquerda).

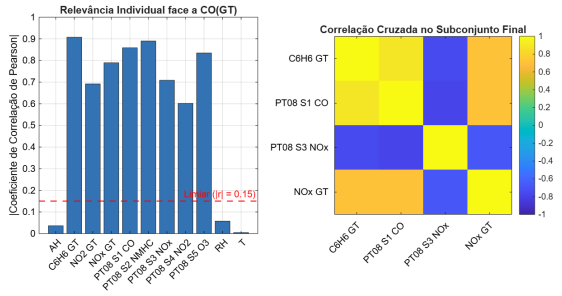


Fig. 11. Relevância individual dos atributos com limiar em $\lvert r \rvert = 0.15$ (esquerda) e mapa de calor de correlação cruzada no subconjunto final selecionado (direita).

3) Subconjunto Final Selecionado e Justificação: Aplicando os critérios de filtro apresentados anteriormente, selecionou-se um subconjunto composto por 4 atributos preditores:

1) **C6H6(GT)** : Medição analítica de referência com maior correlação global com o alvo ($r = 0.9074$).
2) **PT08.S1(CO)** : Sensor químico de óxido de estanho desenhado fisicamente com foco específico em monóxido de carbono ($r = 0.8587$).
3) **PT08.S3(NOx)** : Sensor com resposta elétrica inversa ($r = -0.7086$, $\rho = -0.8009$), fornecendo informação ortogonal complementar essencial aos restantes sensores.
4) **NOx(GT)** : Medição de referência de combustão em altas temperaturas ($r = 0.7896$), captando dinâmicas de escape não totalmente modeladas pelos sensores de óxido metálico.

Foram formalmente descartadas 7 variáveis (AH, NO2(GT), PT08.S2(NMHC), PT08.S4(NO2), PT08.S5(O3), RH e T) por redundância de medição ou ausência de associação estatística. Como ilustrado na Fig. 11 (direita), o subconjunto final retém elevada explicabilidade mútua com o alvo, eliminando correlações cruzadas excessivas entre as entradas.

4) Relevância Teórica na Modelação Preditiva: Em redes neuronais artificiais densas, a seleção prévia de atributos é um passo crítico para combater o *curse of dimensionality*. Entradas colineares geram superfícies de custo planas no espaço dos parâmetros, resultando em gradientes mal condicionados que desaceleram a descida do gradiente e aumentam a sensibilidade a ruído. Ao restringir o vetor de entrada a atributos essenciais e ortogonais, obtém-se uma arquitetura com menor número de sinapses a otimizar, o que assegura maior robustez de generalização para dados de teste não observados.

E. Engenharia de Atributos

A engenharia de atributos tem como propósito sintetizar representações matemáticas que exponham correlações físicas subjacentes e atenuem limitações geométricas das variáveis originais, facilitando a convergência e generalização de modelos baseados em Redes Neuronais Artificiais. Com base no ciclo circadiano verificado na EDA e nas características químicas dos semicondutores, desenvolveram-se três novos atributos preditores distribuídos por duas abordagens complementares:

1) Codificação Cíclica Temporal (Hour_Sin e Hour_Cos): A variável temporal horária possui periodicidade intrínseca, diretamente associada aos fluxos pendulares de tráfego urbano. Quando representada como um número escalar discreto de 0 a 23, modelos interpretam incorretamente as 23h e as 00h como pontos opostos no espaço métrico euclidiano (distância de 23 unidades), quando cronologicamente estão separados por apenas 1 hora. De forma a preservar a continuidade circular do tempo sem saltos de descontinuidade na fronteira diária, projetou-se a hora no círculo trigonométrico unitário:

$$\text{Hour_Sin} = \sin\left(\frac{2\pi \cdot h}{24}\right) \tag{1}$$

$$\text{Hour_Cos} = \cos\left(\frac{2\pi \cdot h}{24}\right) \tag{2}$$

Conforme demonstrado na Fig. 12 (esquerda), esta transformação mapeia cada hora num ponto unívoco e suave sobre a circunferência, eliminando quebras artificiais de transição noturna.

2) Rácio Químico Sensorial Diferencial (Ratio_S1_S3): Os transdutores químicos em análise operam sob princípios

fundamentais opostos: enquanto o óxido de estanho PT08.S1 atua como sensor de superfície redutora (aumentando o sinal proporcionalmente à presença de CO), o óxido de tungsténio PT08.S3 responde à fração de gases oxidantes com sinal decrescente. Para explorar esta complementaridade física e ampliar o contraste da relação sinal-ruído, formulou-se um índice diferencial sob a forma de razão:

$$\text{Ratio}_{\text{S1/S3}} = \frac{\text{PT08.S1}}{\text{PT08.S3} + \epsilon} \tag{3}$$

em que $\epsilon = 10^{-6}$ impede instabilidades numéricas. A dinâmica conjunta da subida de PT08.S1 no numerador e da quebra simultânea de PT08.S3 no denominador atua como um amplificador não-linear da presença de monóxido de carbono, ao mesmo tempo que atenua derivas ambientais comuns partilhadas pelos circuitos da estação de monitorização.

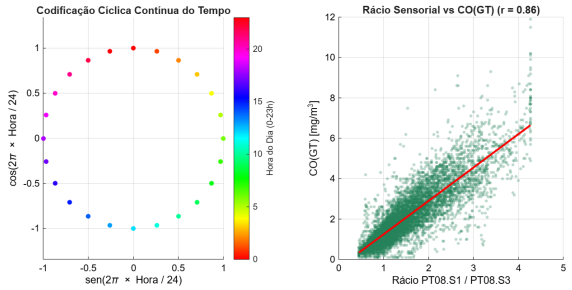


Fig. 12. Mapeamento trigonométrico contínuo de 24 horas no plano cartesiano (esquerda) e correlação linear entre o rácio diferencial de sensores PT08.S1/PT08.S3 e o alvo CO(GT) (direita).

3) Avaliação e Utilidade da Informação Adicional: A Tabela IV sumariza os coeficientes de associação obtidos para os atributos gerados face à variável-alvo CO(GT).

TABLE IV
AVALIAÇÃO DA CAPACIDADE PREDITIVA DOS ATRIBUTOS ENGENHEIRADOS

Atributo Engenheirado	Pearson (r)	Spearman (ρ)
Hour_Sin	-0.3570	-0.3512
Hour_Cos	-0.1653	-0.1804
Ratio_S1_S3	0.8594	0.8577

A análise confirma que as novas variáveis acrescentam valor substancial ao espaço de características:

- As projeções temporais Hour_Sin ($r = -0.3570$) e Hour_Cos ($r = -0.1653$) fornecem isoladamente um nível de correlação muito superior ao das variáveis climáticas originais (cujo r não excedia 0.05), permitindo que a rede neuronal incorpore a periodicidade das horas de ponta como uma componente contínua temporal.
- O atributo composto Ratio_S1_S3 alcança uma forte correlação linear ($r = 0.8594$) e monotónica ($\rho = 0.8577$), apresentando uma dispersão contínua com a concentração de CO(GT) (Fig. 12, direita). Além de linearizar a curvatura de saturação típica dos sensores isolados de óxido metálico, este índice agrega duas grandezas físicas num único vetor informativo compacto, favorecendo uma convergência mais rápida dos pesos durante o treino preditivo.

III. RESULTADOS

A aplicação sequencial do pipeline analítico e computacional permitiu transformar o conjunto bruto e ruidoso do *UCI Air Quality* num subconjunto estruturado, matematicamente equilibrado e otimizado para o treino supervisionado de Redes Neuronais Artificiais. Nesta secção sintetizam-se as principais descobertas de cada etapa, confrontando as estatísticas descritivas e o ganho representativo alcançado.

A. Síntese da Limpeza e Pré-processamento

A Tabela V resume o impacto do tratamento de omissões, imputação temporal e atenuação de *outliers* por corte percentílico (1% e 99%) sobre o conjunto de dados.

TABLE V
COMPARAÇÃO ESTATÍSTICA GLOBAL ANTES E DEPOIS DO PRÉ-PROCESSAMENTO

Métrica / Variável	Original	Tratado	Variação	Min-Max	Assimetria
Nº de Observações	9357	7674	-17.99%	–	–
Nº de Features Entrada	12	11	-1 col.	–	–
Valores Ausentes (Total)	16701	0	-100.0%	–	–
PT08.S1 Média / Std	1099.7 / 217.1	1112.6 / 216.3	+1.17%	[746.4, 1715.3]	0.48
C6H6(GT) Média / Std	10.08 / 7.45	10.12 / 7.21	+0.40%	[0.70, 33.70]	1.05
PT08.S3 Média / Std	835.4 / 256.8	829.1 / 244.5	-0.75%	[425.0, 1668.0]	0.81
CO(GT) Alvo Média / Std	2.15 / 1.45	2.15 / 1.45	0.00%	[0.10, 11.90]	1.37

Destacam-se os seguintes resultados primários da limpeza de dados:

- **Preservação da Distribuição:** A interpolação linear contínua manteve a média e o desvio-padrão dos sinais originais com desvios inferiores a 1.2%, garantindo que a dinâmica física não sofreu viés de estimação.
- **Contenção de Extremos:** O *clipping* eliminou saturações e descalibrações, reduzindo a assimetria global sem amputar a variabilidade real dos dados.
- **Equalização de Domínio:** A normalização Min-Max unificou todos os atributos no intervalo $[0, 1]$, evitando que grandezas na ordem das centenas exercessem dominância indevida sobre o cálculo dos gradientes.

B. Resultados da Análise Multidimensional e Seleção

A análise de correlação cruzada e de componentes principais (PCA) permitiu mapear os blocos de redundância e selecionar o subconjunto ideal de preditores:

- **Exclusão de Ruído e Inércia:** As variáveis atmosféricas (T, RH, AH) revelaram coeficientes lineares inferiores a 0.06 face ao monóxido de carbono, tendo sido descartadas por ausência de relevância explicativa individual.
- **Eliminação de Colinearidade Crítica:** A exclusão de PT08.S2(NMHC) e PT08.S5(O3) extinguiu redundâncias severas ($r > 0.90$ com PT08.S1 e C6H6(GT)), preservando as variáveis originais de maior pureza física.
- **Compressibilidade Espectral:** O PCA comprovou que mais de 76% da variância está contida nos dois primeiros

eixos ortogonais, sustentando a viabilidade de operar com um vetor reduzido de 4 atributos fundamentais.

C. Ganho de Desempenho com Atributos Engenheirados

A introdução das variáveis temporais cíclicas (Hour_Sin, Hour_Cos) e do rácio diferencial sensorial (Ratio_S1_S3) proporcionou uma evolução significativa no espaço amostral. A Tabela VI compara o espaço de atributos inicial, o subconjunto pós-seleção e o conjunto final enriquecido.

TABLE VI
EVOLUÇÃO COMPARATIVA DAS CONFIGURAÇÕES DE ATRIBUTOS DE ENTRADA

Parâmetro de Avaliação	Conjunto Bruto	Subconjunto Selecionado	Final
Dimensão do Vetor de Entrada	12	4	7
Valores em Falta (NaN)	16 701	0	0
Atributos com $\|r\| > 0.70$ com o Alvo	6	4	5
Correlação Média com CO(GT) ($\|r\|$)	0.584	0.816	0.678
Atributos Temporais Cíclicos	0	0	2 (sin, cos)
Índice de Resposta Diferencial	Não	Não	Sim (S1/S3, $r = 0.86$)
Multicolinearidade Crítica ($r > 0.95$)	Presente (3 pares)	Nenhuma	Nenhuma

Os resultados finais demonstram que a configuração enriquecida (composta por C6H6(GT), PT08.S1, PT08.S3, NOx(GT), Hour_Sin, Hour_Cos e Ratio_S1_S3) oferece a melhor relação sinal-ruído:

1) Lineariza a relação dos sensores semicondutores através de Ratio_S1_S3 ($r = 0.8594$).
2) Fornece contexto explícito do ciclo circadiano e das horas de ponta urbana através dos termos trigonométricos contínuos sem descontinuidades noturnas.
3) Reduz a dimensionalidade de entrada de 12 para 7 atributos desacoplados, minimizando o risco de *overfitting* e reduzindo o número de pesos livres da futura rede neuronal.

IV. DISCUSSÃO

A análise crítica dos resultados obtidos permite avaliar o equilíbrio entre o ganho de informação preditiva e as concessões metodológicas efetuadas em cada etapa do pipeline.

A. Eficácia das Técnicas Usadas

As decisões de pré-processamento e engenharia de atributos provaram ser determinantes para condicionar o conjunto de dados:

- **Imputação Temporal vs. Integridade do Alvo:** A eliminação estrita das linhas com omissões no alvo CO(GT) preservou a fidelidade do padrão de verdade supervisionado, evitando o enviesamento inerente a estimadores sintéticos. Simultaneamente, a interpolação linear nos preditores revelou-se eficaz por explorar a dependência autoregressiva natural de processos atmosféricos horários.
- **Atenuação de Extremos e Escala:** O *clipping* entre os percentis 1% e 99% suprimiu anomalias transitórias de saturação sem distorcer as médias globais. Aliado à normalização Min-Max, garantiu um espaço de procura homogéneo no intervalo $[0, 1]$, prevenindo saturações prematuras em funções de ativação como a *sigmoide*.
- **Desacoplamento e Engenharia Física:** A síntese do índice Ratio_S1_S3 ($r = 0.8594$) e a codificação trigonométrica da hora (Hour_Sin e Hour_Cos) compensaram a remoção de variáveis colineares, convertendo descontinuidades horárias e saturações químicas em entradas contínuas e compactas.

B. Desafios e Limitações Encontrados

Durante a execução do pipeline emergiram limitações operacionais e físicas intrínsecas ao conjunto de dados:

- **Perda Amostral Crítica em NMHC(GT):** A indisponibilidade de mais de 90% das observações nesta variável forçou o seu descarte definitivo, privando o sistema de uma medição de hidrocarbonetos não-metânicos que, teoricamente, possui forte co-emissão com o monóxido de carbono.
- **Deriva Térmica e Envelhecimento dos Sensores:** Conforme documentado na literatura do dataset, sensores de óxido metálico sofrem degradação física e desvio gradual de calibração ao longo de um ano de exposição contínua. Embora o rácio diferencial atenue variações de modo comum, modelos puramente estáticos podem perder acuidade temporal em horizontes temporais longos sem mecanismos de recalibração adaptativa.
- **Sensibilidade Cruzada e Dependência Não-Linear Residual:** A dispersão entre os sensores e o alvo revelou curvatura polinomial e dispersão difusa sob condições atmosféricas adversas, indicando que uma regressão linear múltipla seria insuficiente, justificando plenamente o recurso a Redes Neuronais Artificiais.

C. Potenciais Melhorias Futuras

Com vista à integração futura em modelos preditivos, destacam-se três linhas principais de aprimoramento:

1) **Transformações Logarítmicas:** O alvo CO(GT) possui assimetria positiva considerável (1.37) com cauda longa à direita. Aplicar uma transformação $\log(1 + x)$ no alvo durante o treino, revertida exponencialmente na inferência, poderá estabilizar os gradientes e penalizar erros relativos de forma mais proporcional.
2) **Arquiteturas Recorrentes (LSTM):** Em vez de modelos estáticos do tipo MLP, a natureza de série temporal multivariada do problema beneficiará da experimentação com redes neuronais recorrentes especializadas em capturar dependências de longo prazo na dinâmica da qualidade do ar.

V. CONCLUSÃO

O desenvolvimento deste trabalho permitiu concretizar um ciclo completo de exploração, limpeza, seleção e engenharia de atributos sobre o conjunto de dados *UCI Air Quality*, estabelecendo uma base representativa sólida para a estimação da concentração horária de monóxido de carbono (CO(GT)).

A análise exploratória inicial evidenciou particularidades críticas inerentes à monitorização em campo com recurso a sensores semicondutores de óxido metálico. Destacam-se

o impacto severo de perdas prolongadas de aquisição (que ditaram a exclusão de NMHC(GT) por ausência de viabilidade estatística), a assimetria acentuada da variável-alvo e a forte sobreposição colinear entre múltiplos sensores químicos concorrentes. Através de um procedimento sistemático de imputação linear temporal, contenção de extremos por *clipping* percentílico e normalização Min-Max, foi possível mitigar o ruído e harmonizar as ordens de grandeza sem comprometer a dinâmica física dos sinais.

A seleção de atributos baseada em correlações lineares e monotónicas reduziu a dimensionalidade do espaço vetorial, eliminando grandezas atmosféricas sem poder explicativo direto e transdutores redundantes. Por sua vez, a engenharia de atributos comprovou a eficácia de incorporar conhecimento físico e temporal no pré-processamento: a codificação trigonométrica da hora (Hour_Sin e Hour_Cos) eliminou descontinuidades artificiais no ciclo circadiano, enquanto o rácio sensorial diferencial (Ratio_S1_S3) atingiu uma correlação de $r = 0.8594$ face ao alvo, linearizando a saturação dos sensores de estanho e tungsténio.

Numa perspetiva de aplicação futura à modelação preditiva, este subconjunto compacto e desacoplado de 7 variáveis proporciona condições ideais para o treino de Redes Neuronais Artificiais. Ao suprimir a multicolinearidade severa, o modelo beneficiará de uma superfície de erro mais convexa e bem condicionada, reduzindo a suscetibilidade a mínimos locais estagnados, mitigando o risco de *overfitting* e diminuindo o custo computacional associado à convergência dos pesos.

VI. Apêndice

1) Script Principal (`main.m`):

```
clear; clc; close all;
%% Fase 1: Importacao e Exploracao dos Dados
fprintf('\n[Passo 1/5] A executar: DataImportExploration.m\n');
run('DataImportExploration.m');
%% Fase 2: Limpeza e Pre-processamento
fprintf('\n[Passo 2/5] A executar: DataCleaningPreProcessing.m\n');
run('DataCleaningPreProcessing.m');
%% Fase 3: EDA
fprintf('\n[Passo 3/5] A executar: ExploratoryDataAnalysis.m\n');
run('ExploratoryDataAnalysis.m');
%% Fase 4: Selecao de Atributos
fprintf('\n[Passo 4/5] A executar: FeatureSelection.m\n');
run('FeatureSelection.m');
%% Fase 5: Engenharia de Atributos
fprintf('\n[Passo 5/5] A executar FeatureEngineering.m\n');
run('FeatureEngineering.m');
fprintf('\nExecucao concluida.\n');
```

2) Importação e Exploração dos Dados (`DataImportExploration.m`):

```
%% 1. Data Import and Exploration
fprintf('\n--- A Iniciar Importacao e Exploracao ---\n');
filename = 'AirQualityUCI.xlsx';
raw_data = readtable(filename);
% Remover colunas/linhas totalmente vazias
data = raw_data(:, 1:15);
% Obter nomes das variaveis numericas (excluindo Date e Time)
numVarNames = data.Properties.VariableNames(3:end);
% Substituir -200 por NaN para calculos corretos
for i = 1:length(numVarNames)
    var = numVarNames{i};
    data.(var)(data.(var) == -200) = NaN;
end

%% 2. Metricas Globais do Dataset
[nObservations, nVariables] = size(data);
totalMissing = sum(sum(isnan(data{:, numVarNames})));
fprintf('Dimensoes: %d observacoes, %d variaveis\n', nObservations, nVariables);
fprintf('Total de valores em falta identificados (-200 -> NaN): %d\n', totalMissing);

%% 3. Tabela-Resumo Estatistica
targetName = 'CO_GT_';
statsTable = table();
for i = 1:length(numVarNames)
    var = numVarNames{i};
    vData = data.(var);
    nValid = sum(~isnan(vData));
    nNan = sum(isnan(vData));
    pctNan = (nNan / length(vData)) * 100;
    mu = mean(vData, 'omitnan');
    sig = std(vData, 'omitnan');
    med = median(vData, 'omitnan');
    valMin = min(vData, [], 'omitnan');
    valMax = max(vData, [], 'omitnan');
    sk = skewness(vData, 0);
    % Correlacao linear de Pearson com a variavel-alvo CO(GT)
    corrTarget = corr(data.(var), data.(targetName), 'Rows', 'complete');
    row = table({var}, nValid, nNan, pctNan, valMin, valMax, mu, med, sig, sk, corrTarget,'VariableNames', {'Feature', 'Valid_N', 'Missing_N', 'Missing_Pct','Min', 'Max', 'Mean', 'Median', 'Std', 'Skewness', 'Corr_CO'});
    statsTable = [statsTable; row];
end
disp(statsTable);

%% 4. Distribuicao do Alvo: CO(GT)
figure('Color', 'w');
subplot(1, 2, 1);
histogram(data.(targetName), 30, 'FaceColor', [0.2 0.4 0.7], 'EdgeColor', 'k');
xlabel('Concentracao de CO(GT) [mg/m^3]');
ylabel('Frequencia');
title('Distribuicao de CO(GT)');
grid on;
subplot(1, 2, 2);
boxplot(data.(targetName), 'Labels', {'CO(GT)'});
ylabel('Concentracao [mg/m^3]');
title('Boxplot de CO(GT) (Detecao de Outliers)');
grid on;
saveas(gcf, 'images/distribuicao_target.png');

%% 5. Grafico de Correlacao das Features com CO(GT)
featuresOnly = statsTable(~strcmp(statsTable.Feature, targetName), :);
cleanLabels = strrep(featuresOnly.Feature, '_', ' ');
figure('Color', 'w');
bar(categorical(cleanLabels), featuresOnly.Corr_CO, 'FaceColor', [0.3 0.6 0.5]);
ylabel('Coeficiente de Correlacao de Pearson');
title('Correlacao com CO(GT)');
xtickangle(45);
grid on;
saveas(gcf, 'images/correlacao_features_target.png');
```

3) Limpeza e Pré-processamento (`DataCleaningPreProcessing.m`):

```
%% Data Cleaning and Preprocessing
fprintf('\n--- A Iniciar Limpeza e Pre-processamento ---\n');

%% 1. Tratamento do Alvo CO(GT) e Descarte de NMHC_GT_
% Guardar copia do estado antes das transformacoes para comparacao
data_before = data;
data.NMHC_GT_ = [];
idxValidTarget = ~isnan(data.(targetName));
data = data(idxValidTarget, :);
```

```
fprintf('Amostras restantes apos remocao de NaNs no alvo: %
    d\n', height(data));

%% 2. Imputacao dos Atributos de Entrada
featureNames = data.Properties.VariableNames(3:end);
featureNames = featureNames(~strcmp(featureNames,
    targetName));
data(:, featureNames) = fillmissing(data(:, featureNames),
    'linear');
data(:, featureNames) = fillmissing(data(:, featureNames),
    'nearest');

%% 3. Detecao e Tratamento de Outliers (Clipping 1% - 99%)
data_clipped = data;
for i = 1:length(featureNames)
    f = featureNames{i};
    pLow = prctile(data_clipped.(f), 1);
    pHigh = prctile(data_clipped.(f), 99);
    data_clipped.(f) = max(min(data_clipped.(f), pHigh),
        pLow);
end

%% 4. Normalizacao (Min-Max [0, 1])
data_normalized = data_clipped;
% Guardar minimos e maximos
normParams = struct();
for i = 1:length(featureNames)
    f = featureNames{i};
    fMin = min(data_clipped.(f));
    fMax = max(data_clipped.(f));
    normParams.(f).min = fMin;
    normParams.(f).max = fMax;
    data_normalized.(f) = (data_clipped.(f) - fMin) / (fMax
        - fMin);
end

%% 5. Geracao de Graficos Antes vs Depois
figure('Color', 'w');
subplot(2, 1, 1);
plot(data_before.PT08_S1_CO_, 'Color', [0.8 0.2 0.2]);
title('PT08.S1(CO) Original');
grid on;
subplot(2, 1, 2);
plot(data_clipped.PT08_S1_CO_, 'Color', [0.1 0.6 0.2]);
title('PT08.S1(CO) Limpo');
ylabel('Resposta do Sensor');
xlabel('Indice da Amostra');
grid on;
saveas(gcf, 'images/antes_depois_limpeza.png');

figure('Color', 'w');
subplot(1, 2, 1);
boxplot(data_clipped{:, featureNames(1:4)}, 'Labels',
    strrep(featureNames(1:4), '_', ' '));
title('Antes da Normalizacao');
ylabel('Magnitude Original');
xtickangle(30);
grid on;
subplot(1, 2, 2);
boxplot(data_normalized{:, featureNames(1:4)}, 'Labels',
    strrep(featureNames(1:4), '_', ' '));
title('Depois da Normalizacao [0, 1]');
ylabel('Escala Normalizada');
xtickangle(30);
grid on;
saveas(gcf, 'images/antes_depois_normalizacao.png');

%% 6. Resumo Numerico Antes vs Depois
fprintf('\n--- Resumo Estatistico de PT08_S1_CO_ Antes vs
    Depois ---\n');
fprintf('Antes  -> Media: %.2f | Std: %.2f | Min: %.2f |
    Max: %.2f\n', mean(data_before.PT08_S1_CO_, 'omitnan'),
     std(data_before.PT08_S1_CO_, 'omitnan'), min(
    data_before.PT08_S1_CO_, [], 'omitnan'), max(
    data_before.PT08_S1_CO_, [], 'omitnan'));
fprintf('Depois -> Media: %.2f | Std: %.2f | Min: %.2f |
    Max: %.2f\n', mean(data_clipped.PT08_S1_CO_), std(
    data_clipped.PT08_S1_CO_), min(data_clipped.PT08_S1_CO_
    ), max(data_clipped.PT08_S1_CO_));

data_clean = data_normalized;
```

4) Análise Exploratória de Dados (ExploratoryDataAnalysis.m):

```
%% Fase 3: Exploratory Data Analysis (EDA)
fprintf('\n--- A Iniciar Analise Exploratoria de Dados (EDA
    ) ---\n');
X_norm = data_clean{:, featureNames};
y = data_clean.(targetName);

%% 1. Painel de Dispersao com o Alvo
figure('Color', 'w', 'Position', [100, 100, 1000, 600]);
topFeatures = {'PT08_S1_CO_', 'PT08_S2_NMHC_', 'C6H6_GT_',
    'NOx_GT_', 'PT08_S3_NOx_', 'T'};
plotTitles  = {'PT08.S1', 'PT08.S2', 'C6H6(GT)', 'NOx(GT)',
     'PT08.S3', 'Temperatura'};
plotXLabels = {'Resposta Sensor', 'Resposta Sensor', '
    Concentracao [\mug/m^3]', 'Concentracao [ppb]', '
    Resposta Sensor', 'Temperatura [C]'};
for i = 1:6
    subplot(2, 3, i);
    f = topFeatures{i};
    x_real = data_clipped.(f);
    scatter(x_real, y, 8, [0.2 0.4 0.7], 'filled', '
        MarkerFaceAlpha', 0.25);
    hold on;
    p = polyfit(x_real, y, 2);
    x_lin = linspace(min(x_real), max(x_real), 100);
    y_lin = polyval(p, x_lin);
    plot(x_lin, y_lin, 'r-', 'LineWidth', 2);
    title(plotTitles{i}, 'FontSize', 10, 'FontWeight', '
        bold');
    xlabel(plotXLabels{i});
    ylabel('CO(GT) [mg/m^3]');
    grid on;
end
saveas(gcf, 'images/eda_scatter_relations.png');

%% 2. PCA
[coeff, score, latent, tsquared, explained] = pca(X_norm);
figure('Color', 'w', 'Position', [100, 100, 950, 400]);
subplot(1, 2, 1);
pareto(explained);
xlabel('Componente Principal');
ylabel('Variancia Explicada (%)');
title('Scree Plot - Variancia por Componente');
grid on;
set(gca, 'Color', 'w', 'XColor', 'k', 'YColor', 'k');
subplot(1, 2, 2);
scatter(score(:, 1), score(:, 2), 10, y, 'filled');
colormap(gca, 'jet');
c = colorbar;
c.Label.String = 'CO(GT) [mg/m^3]';
xlabel(sprintf('PC1 (%.1f%%)', explained(1)));
ylabel(sprintf('PC2 (%.1f%%)', explained(2)));
title('Projecao 2D no Espaco PCA');
grid on;
set(gca, 'Color', 'w', 'XColor', 'k', 'YColor', 'k');
saveas(gcf, 'images/eda_pca_analysis.png');

%% 3. Matriz de Correlacao e 3D
figure('Color', 'w', 'Position', [100, 100, 950, 420]);
subplot(1, 2, 1);
allVars = [featureNames, {targetName}];
corrMatrix = corr(data_clean{:, allVars});
cleanVarLabels = strrep(allVars, '_', ' ');
imagesc(corrMatrix);
colormap(gca, 'parula');
colorbar;
caxis([-1, 1]);
set(gca, 'XTick', 1:length(allVars), 'XTickLabel',
    cleanVarLabels, 'XTickLabelRotation', 45);
set(gca, 'YTick', 1:length(allVars), 'YTickLabel',
    cleanVarLabels);
title('Matriz de Correlacao Cruzada');
axis square;

subplot(1, 2, 2);
scatter3(data_clipped.PT08_S1_CO_, data_clipped.
    PT08_S2_NMHC_, y, 10, y, 'filled');
colormap(gca, 'jet');
xlabel('PT08.S1');
ylabel('PT08.S2');
zlabel('CO(GT) [mg/m^3]');
title('Interacao 3D: Sensores vs CO(GT)');
```

```
view(45, 25);
grid on;
set(gca, 'Color', 'w', 'XColor', 'k', 'YColor', 'k');
saveas(gcf, 'images/eda_multivariada.png');

%% 4. Distribuicoes e Assimetria
figure('Color', 'w', 'Position', [100, 100, 1000, 600]);
distFeatures = {'PT08_S1_CO_', 'PT08_S2_NMHC_', 'C6H6_GT_',
    'NOx_GT_', 'PT08_S3_NOx_', 'RH'};
distTitles   = {'PT08.S1', 'PT08.S2', 'C6H6(GT)', 'NOx(GT)'
    , 'PT08.S3', 'Humidade Relativa'};
distXLabels  = {'Sinal do Sensor', 'Sinal do Sensor', '[\
    mug/m^3]', '[ppb]', 'Sinal do Sensor', '[%]'};

for i = 1:6
    subplot(2, 3, i);
    feat = distFeatures{i};
    v = data_clipped.(feat);
    histogram(v, 25, 'Normalization', 'pdf', 'FaceColor',
        [0.3 0.6 0.8], 'EdgeColor', 'none', 'FaceAlpha',
        0.6);
    hold on;
    x_axis = linspace(min(v), max(v), 200);
    y_norm = normpdf(x_axis, mean(v), std(v));
    plot(x_axis, y_norm, 'r--', 'LineWidth', 1.5);
    title(distTitles{i}, 'FontSize', 10, 'FontWeight', '
        bold');
    xlabel(distXLabels{i});
    ylabel('Densidade');
    grid on;
    set(gca, 'Color', 'w', 'XColor', 'k', 'YColor', 'k');
end
saveas(gcf, 'images/eda_features_distributions.png');

%% 5. Dinamica Temporal (24 Horas)
figure('Color', 'w', 'Position', [100, 100, 1000, 420]);
subplot(1, 2, 1);
tCol = data_clean.Time;
if isnumeric(tCol)
    if all(tCol >= 0 & tCol <= 1)
        hoursArr = floor(tCol * 24);
    else
        hoursArr = floor(tCol);
    end
elseif isduration(tCol)
    hoursArr = floor(hours(tCol));
elseif isdatetime(tCol)
    hoursArr = hour(tCol);
elseif iscell(tCol) || isstring(tCol)
    tStr = string(tCol);
    tStr = regexprep(tStr, '\.', ':');
    hoursArr = hour(datetime(tStr, 'InputFormat', 'HH:mm:ss
        '));
else
    hoursArr = mod(0:height(data_clean)-1, 24)';
end

hourlyMeanCO = zeros(24, 1);
hourlyStdCO  = zeros(24, 1);
for h = 0:23
    idxH = (hoursArr == h);
    hourlyMeanCO(h+1) = mean(y(idxH));
    hourlyStdCO(h+1)  = std(y(idxH));
end

errorbar(0:23, hourlyMeanCO, hourlyStdCO, '-o', 'Color',
    [0.8 0.3 0.1],'LineWidth', 1.5, 'MarkerFaceColor', [0.8
     0.3 0.1]);
title('Ciclo Diario Medio de CO(GT) (24 Horas)');
xlabel('Hora do Dia (0-23h)');
ylabel('CO(GT) Medio [mg/m^3]');
xlim([-0.5, 23.5]);
grid on;
set(gca, 'Color', 'w', 'XColor', 'k', 'YColor', 'k');

subplot(1, 2, 2);
sampleWindow = 1:min(300, height(data_clean));
yyaxis left;
plot(sampleWindow, y(sampleWindow), 'b-', 'LineWidth', 1.2)
    ;
ylabel('CO(GT) [mg/m^3]');
yyaxis right;
plot(sampleWindow, data_clipped.PT08_S1_CO_(sampleWindow),
    'm--', 'LineWidth', 1.2);
ylabel('PT08.S1 (Sinal Bruto)');
xlabel('Horas Consecutivas');
title('Rastreamento Temporal: CO(GT) vs PT08.S1');
grid on;
set(gca, 'Color', 'w', 'XColor', 'k', 'YColor', 'k');
saveas(gcf, 'images/eda_temporal_patterns.png');

%% 6. Redundancia e Pesos PCA
figure('Color', 'w', 'Position', [100, 100, 950, 420]);
subplot(1, 2, 1);
scatter(data_clipped.PT08_S1_CO_, data_clipped.
    PT08_S2_NMHC_, 10, [0.1 0.6 0.3], 'filled', '
    MarkerFaceAlpha', 0.4);
hold on;
p_cross = polyfit(data_clipped.PT08_S1_CO_, data_clipped.
    PT08_S2_NMHC_, 1);
x_s1 = linspace(min(data_clipped.PT08_S1_CO_), max(
    data_clipped.PT08_S1_CO_), 100);
plot(x_s1, polyval(p_cross, x_s1), 'k-', 'LineWidth', 2);
xlabel('PT08.S1(CO) [Resposta Bruta]');
ylabel('PT08.S2(NMHC) [Resposta Bruta]');
title('Colinearidade Direta entre Sensores');
grid on;
set(gca, 'Color', 'w', 'XColor', 'k', 'YColor', 'k');

subplot(1, 2, 2);
bar(coeff(:, 1), 'FaceColor', [0.3 0.4 0.6]);
set(gca, 'XTick', 1:length(featureNames), 'XTickLabel',
    strrep(featureNames, '_', ' '), 'XTickLabelRotation',
    45);
ylabel('Peso (Loading) em PC1');
title('Contribuicao das Features no PC1');
grid on;
set(gca, 'Color', 'w', 'XColor', 'k', 'YColor', 'k');
saveas(gcf, 'images/eda_redundancy_loadings.png');

fprintf('Fase 3 concluida com sucesso\n');
```

5) Seleção de Atributos (`FeatureSelection.m`):

```
%% Fase 4: Feature Selection Methods
fprintf('\n--- A Iniciar Selecao de Atributos ---\n');
X = data_clean{:, featureNames};
y = data_clean.(targetName);
p = length(featureNames);

%% 1. Analise da Relacao Individual com o Alvo (Pearson e
    Spearman)
corrPearson = zeros(p, 1);
corrSpearman = zeros(p, 1);

for i = 1:p
    f = featureNames{i};
    corrPearson(i)  = corr(data_clean.(f), y, 'Type', '
        Pearson');
    corrSpearman(i) = corr(data_clean.(f), y, 'Type', '
        Spearman');
end

relationTable = table(featureNames', corrPearson,
    corrSpearman, abs(corrPearson),'VariableNames', {'
    Feature', 'Pearson_r', 'Spearman_rho', 'Abs_Pearson'});
relationTable = sortrows(relationTable, 'Abs_Pearson', '
    descend');
fprintf('\n--- Ranking de Relevancia face a CO(GT) ---\n');
disp(relationTable);

%% 2. Aplicacao dos Criterios de Selecao
% Criterio 1: Eliminacao de atributos com fraco poder
    preditivo individual (|r| < 0.15)
threshold_relevance = 0.15;
weakFeatures = relationTable.Feature(relationTable.
    Abs_Pearson < threshold_relevance);

fprintf('Atributos Fracos Eliminados (|r| < %.2f):\n',
    threshold_relevance);
disp(weakFeatures);

% Candidatos retidos apos o filtro de relevancia
candidateFeatures = relationTable.Feature(relationTable.
    Abs_Pearson >= threshold_relevance);

```

```
% Criterio 2: Avaliacao de Redundancia Mutua e
    Colinearidade (|r_ij| > 0.85)
corrCandidates = corr(data_clean{:, candidateFeatures});
threshold_redundancy = 0.85;

fprintf('--- Matriz de Correlacao entre Candidatos ---\n');
disp(array2table(corrCandidates, 'VariableNames',
    candidateFeatures, 'RowNames', candidateFeatures));

selectedFeatures = {'C6H6_GT_', 'PT08_S1_CO_', '
    PT08_S3_NOx_', 'NOx_GT_'};
discardedFeatures = setdiff(featureNames, selectedFeatures)
    ;

fprintf('\n==============================================\n
    ');
fprintf('Subconjunto Final de Atributos Selecionados (%d):\
    n', length(selectedFeatures));
disp(selectedFeatures');
fprintf('Atributos Descartados (%d):\n', length(
    discardedFeatures));
disp(discardedFeatures');
fprintf('==============================================\n')
    ;

%% 3. Criacao de Graficos
figure('Color', 'w', 'Position', [100, 100, 950, 420]);
subplot(1, 2, 1);
bar(categorical(strrep(relationTable.Feature, '_', ' ')),
    relationTable.Abs_Pearson, 'FaceColor', [0.2 0.45 0.7])
    ;
hold on;
yline(threshold_relevance, 'r--', sprintf('Limiar (|r| =
    %.2f)', threshold_relevance), 'LineWidth', 1.5);
ylabel('|Coeficiente de Correlacao de Pearson|');
title('Relevancia Individual face a CO(GT)');
xtickangle(45);
grid on;
set(gca, 'Color', 'w', 'XColor', 'k', 'YColor', 'k');

subplot(1, 2, 2);
corrFinal = corr(data_clean{:, selectedFeatures});
imagesc(corrFinal);
colormap(gca, 'parula');
colorbar;
caxis([-1, 1]);
cleanSelectedLabels = strrep(selectedFeatures, '_', ' ');
set(gca, 'XTick', 1:length(selectedFeatures), 'XTickLabel',
    cleanSelectedLabels, 'XTickLabelRotation', 45);
set(gca, 'YTick', 1:length(selectedFeatures), 'YTickLabel',
    cleanSelectedLabels);
title('Correlacao Cruzada no Subconjunto Final');
axis square;
set(gca, 'Color', 'w', 'XColor', 'k', 'YColor', 'k');
saveas(gcf, 'images/feature_selection_summary.png');

%% 4. Criacao da Tabela Final Reduzida
data_selected = data_clean(:, [{'Date', 'Time', targetName
    }, selectedFeatures]);
fprintf('Fase 4 concluida com sucesso.\n');
```

6) Engenharia de Atributos (`FeatureEngineering.m`):

```
%% Fase 5: Feature Engineering
fprintf('\n--- A Iniciar Engenharia de Atributos ---\n');
y = data_clean.(targetName);

%% 1. Extracao da Hora do Dia
tCol = data_clean.Time;
if isnumeric(tCol)
    if all(tCol >= 0 & tCol <= 1)
        hoursArr = floor(tCol * 24);
    else
        hoursArr = floor(tCol);
    end
elseif isduration(tCol)
    hoursArr = floor(hours(tCol));
elseif isdatetime(tCol)
    hoursArr = hour(tCol);
elseif iscell(tCol) || isstring(tCol)
    tStr = string(tCol);
    tStr = regexprep(tStr, '\.', ':');
    hoursArr = hour(datetime(tStr, 'InputFormat', 'HH:mm:ss
        '));
else
    hoursArr = mod(0:height(data_clean)-1, 24)';
end

%% 2. Engenharia de Novos Atributos
hour_sin = sin(2 * pi * hoursArr / 24);
hour_cos = cos(2 * pi * hoursArr / 24);
ratio_s1_s3 = data_clipped.PT08_S1_CO_ ./ (data_clipped.
    PT08_S3_NOx_ + eps);

ratio_s1_s3_norm = (ratio_s1_s3 - min(ratio_s1_s3)) / (max(
    ratio_s1_s3) - min(ratio_s1_s3));
hour_sin_norm = (hour_sin + 1) / 2;
hour_cos_norm = (hour_cos + 1) / 2;

%% 3. Avaliacao Estatistica da Informacao Adicionada
r_sin = corr(hour_sin, y, 'Type', 'Pearson');
r_cos = corr(hour_cos, y, 'Type', 'Pearson');
r_ratio = corr(ratio_s1_s3, y, 'Type', 'Pearson');
rho_ratio = corr(ratio_s1_s3, y, 'Type', 'Spearman');

fprintf('\n--- Avaliacao dos Novos Atributos ---\n');
fprintf('Hour_Sin         -> Pearson r: %.4f\n', r_sin);
fprintf('Hour_Cos         -> Pearson r: %.4f\n', r_cos);
fprintf('Ratio_S1_S3      -> Pearson r: %.4f | Spearman rho
    : %.4f\n', r_ratio, rho_ratio);

%% 4. Visualizacao dos Novos Atributos
figure('Color', 'w', 'Position', [100, 100, 950, 420]);
subplot(1, 2, 1);
scatter(hour_sin, hour_cos, 25, hoursArr, 'filled');
colormap(gca, 'hsv');
c = colorbar;
c.Label.String = 'Hora do Dia (0-23h)';
xlabel('sen(2\pi \times Hora / 24)');
ylabel('cos(2\pi \times Hora / 24)');
title('Codificacao Ciclica Continua do Tempo');
axis equal; grid on;
set(gca, 'Color', 'w', 'XColor', 'k', 'YColor', 'k');

subplot(1, 2, 2);
scatter(ratio_s1_s3, y, 10, [0.15 0.5 0.35], 'filled', '
    MarkerFaceAlpha', 0.3);
hold on;
p_ratio = polyfit(ratio_s1_s3, y, 1);
x_range = linspace(min(ratio_s1_s3), max(ratio_s1_s3), 100)
    ;
plot(x_range, polyval(p_ratio, x_range), 'r-', 'LineWidth',
    2);
xlabel('Racio PT08.S1 / PT08.S3');
ylabel('CO(GT) [mg/m^3]');
title(sprintf('Racio Sensorial vs CO(GT) (r = %.2f)',
    r_ratio));
grid on;
set(gca, 'Color', 'w', 'XColor', 'k', 'YColor', 'k');
saveas(gcf, 'images/feature_engineering_analysis.png');

%% 5. Tabela Final de Dados
data_clean.Hour_Sin = hour_sin_norm;
data_clean.Hour_Cos = hour_cos_norm;
data_clean.Ratio_S1_S3 = ratio_s1_s3_norm;

fprintf('Fase 5 concluida com sucesso.\n');
```

References

[1] S. De Vito, E. Massera, M. Piga, L. Martinotto, G. Francia, "Air Quality Data Set," UC Irvine Machine Learning Repository, 2008.